

Otimização Multiobjetivo de Percursos Multimodais no Grande Porto

Autores: Diogo José Borges Dias & Diogo Lopes Azevedo

Mestrado em Inteligência Artificial

Universidade do Minho

27 de dezembro de 2025

 github.com/diogoazevedo04/cin

Contexto e Motivação

Desafios da Mobilidade Urbana:

- Crescimento das áreas metropolitanas
- Necessidade de deslocações eficientes
- Compromisso entre tempo e impacto ambiental

Problema Tradicional:

- Sistemas focados apenas em minimizar tempo
- Ignoram emissões de gases de efeito estufa
- Não oferecem alternativas ao utilizador

→ **Abordagem Multiobjetivo**

Objetivos do Projeto

Desenvolvimento de um sistema de apoio à decisão para percursos no Grande Porto considerando:

Objetivo 1

Minimizar tempo total de viagem



Objetivo 2

Minimizar emissões de CO₂



Modos de transporte integrados:

- Metro do Porto
- Autocarros STCP
- Deslocações pedonais

Otimização Multiobjetivo

Definição formal:

$$\min / \max f(x) = (f_1(x), f_2(x), \dots, f_{M(x)}(x))$$

No nosso problema:

$$\min F(x) = (f_{\text{tempo}(x)}, f_{\text{CO}_2(x)})$$

Características:

- Não existe uma única solução ótima
- Objetivos são contraditórios
- Necessidade de encontrar compromissos
- Utilizador escolhe a solução preferida

Dominância de Pareto

Uma solução **x domina y** ($x \prec y$) se:

1. x é pelo menos tão boa quanto y em **todos** os objetivos
2. x é **estritamente melhor** que y em pelo menos um objetivo

Frente de Pareto:

- Conjunto de todas as soluções não dominadas
- Representa os melhores compromissos possíveis
- Objetivo do algoritmo: aproximar esta frente

Modelação do Problema

Representação como grafo multimodal:

$$G = (V, E)$$

onde:

- V = conjunto de paragens de transporte público
- E = conjunto de ligações (arestas)

Cada aresta e possui:

- t_e : tempo necessário para percorrer
- c_e : emissão de CO₂ associada

Funções objetivo:

$$f_{\text{tempo}}(x) = \sum_{e \in x} t_e \quad f_{\text{CO}_2}(x) = \sum_{e \in x} c_e$$

Estrutura do Grafo

Implementação (graph.py):

- Construído a partir de dados GTFS
- Distâncias euclidianas para ligações pedonais
- Cada aresta armazena explicitamente custos

Tipos de ligações:

Tipo	Tempo	CO ₂
Metro	Dados GTFS	Médio
Autocarro	Dados GTFS	Alto
Pedonal	Distância/velocidade	Zero

MOEA/D: Algoritmo Selecionado

Multi-Objective Evolutionary Algorithm based on Decomposition

Ideia principal:

- Decompor problema multiobjetivo em N subproblemas escalares
- Resolver cooperativamente usando vizinhança
- Cada subproblema tem vetor de pesos λ

Vantagens sobre NSGA-II:

- Mais eficiente computacionalmente
- Melhor distribuição das soluções
- Adequado para frentes não convexas

Decomposição do Problema

Vetores de peso:

$$\Lambda = \{\lambda^1, \lambda^2, \dots, \lambda^N\}$$

onde cada $\lambda^i = (\lambda_1^i, \lambda_2^i)$

Função de Tchebycheff:

$$g^{\text{te}}(x|\lambda, z^*) = \max_{j \in \{1,2\}} \{\lambda_j \cdot |f_{j(x)} - z_j^*|\}$$

- z^* : ponto de referência ideal (atualizado dinamicamente)
- Permite lidar com frentes não convexas
- Mantém diversidade entre soluções

Representação das Soluções

Cada solução é um caminho no grafo:

$$x = (v_1, v_2, \dots, v_k)$$

onde:

- $v_i \in V$ representa uma paragem
- (v_i, v_{i+1}) é uma aresta válida

Vantagens:

- Garante validade topológica
- Não requer operadores de reparação
- Facilita incorporação de conhecimento do domínio

Grafo




Figura 1: Grafo de Estações e Formas de Deslocação

Inicialização Heurística

Algoritmo de Dijkstra para gerar população inicial:

Para diferentes vetores de peso $\lambda = (\lambda_1, \lambda_2)$:

$$C_{uv} = \lambda_1 \cdot \frac{t_{uv}}{t_{\max}} + \lambda_2 \cdot \frac{c_{uv}}{c_{\max}}$$

Benefícios:

- Soluções iniciais de elevada qualidade
- Limites inferiores aproximados
- Diversidade na população inicial
- Convergência mais rápida

Operadores Genéticos

Crossover (combinação):

1. Identificar nós comuns
2. Selecionar nó de corte
3. Concatenar percursos

Mutação (exploração):

1. Selecionar dois pontos
2. Remover subcaminho
3. Reconstruir com Dijkstra

Características:

- Adaptados para grafos
- Garantem validade topológica
- Exploração guiada

Implementação no GitHub

Estrutura do repositório:

```
cin/  
├── graph.py      # Construção do grafo multimodal  
├── moead.py      # Implementação do MOEA/D  
├── main.py       # Execução e testes  
├── data/         # Dados GTFS  
└── results/      # Gráficos e análises
```

 github.com/diogoazevedo04/cin

Configuração Experimental

Parâmetros utilizados:

Parâmetro	Valor
Tamanho da população	100
Número de gerações	50
Número de vizinhos	20
Prob. crossover	1.0
Prob. mutação	0.3
Função de agregação	Tchebycheff

Cenários de teste:

- **Simples:** Cordoaria → Torre dos Clérigos
- **Intermédio:** Aliados → Casa da Música
- **Complexo:** Pedras Rubras → Praia Homem do Leme

Resultados: Frente de Pareto

Três perfis de soluções identificados (cenário intermédio):

Perfil	Tempo	CO ₂	Modo
Rápido	41 min	1164 g	Autocarro
Equilibrado	44.1 min	481 g	Metro + A pé
Ecológico	103.7 min	240 g	A pé

Observações:

- Clara natureza conflituosa do problema
- Redução de 79% no CO₂ implica +153% no tempo
- Solução equilibrada oferece compromisso razoável

Cenário Simples




Figura 2: Frente de Pareto e soluções extremas




Figura 3: Distribuição dos tempos de viagem




Figura 4: Evolução da Frente de Pareto




Figura 5: Evolução do hiper-volume

Cenário Intermédio




Figura 6: Frente de Pareto e soluções extremas




Figura 7: Distribuição dos tempos de viagem




Figura 8: Evolução da Frente de Pareto




Figura 9: Evolução do hipervolume

Cenário Complexo




Figura 10: Frente de Pareto e soluções extremas




Figura 11: Distribuição dos tempos de viagem




Figura 12: Evolução da Frente de Pareto




Figura 13: Evolução do hipervolume

Análise de Convergência

Evolução do algoritmo:

- Crescimento rápido da frente nas primeiras gerações
- Estabilização após 30 gerações
- Hipervolume aumenta consistentemente

Indicadores de qualidade:

- Tamanho da frente aumenta progressivamente
- Diversidade mantida ao longo das gerações
- Mutação contribui para melhorias tardias

Vantagens da Abordagem

- ✓ Múltiplos compromissos numa única execução
- ✓ Integração eficaz de conhecimento do domínio
- ✓ Boa cobertura da Frente de Pareto
- ✓ Robustez face à complexidade do grafo
- ✓ Utilizador final escolhe preferência
- ✓ Adaptável a outros critérios (custo, conforto)

Limitações e Trabalho Futuro

Limitações atuais:

- Custo computacional para caminhos longos
- Fatores médios de emissão
- Ausência de dados em tempo real

Trabalho futuro:

- Restrições adicionais
- Dados em tempo real
- Comparar com NSGA-II
- Novos critérios
- Interface web

Demonstração Prática

Como executar o código:

```
# Clonar repositório
git clone https://github.com/diogoazevedo04/cin.git
cd cin

# Instalar dependências
pip install -r requirements.txt

# Executar exemplo
python main.py
```

Output esperado:

- Frente de Pareto visualizada
- Soluções representativas identificadas
- Gráficos de convergência

Conceitos-Chave da UC

Aplicados neste projeto:

- Algoritmos Evolucionários
- Otimização Multiobjetivo
- Dominância de Pareto
- Decomposição de problemas
- Operadores genéticos adaptados
- Inicialização heurística
- Análise de convergência
- Métricas de avaliação

Conclusões

Contribuições principais:

1. Sistema funcional de planeamento multimodal
2. Aplicação bem-sucedida do MOEA/D
3. Operadores específicos para grafos urbanos
4. Validação em cenários reais do Porto

Impacto:

- Suporte à decisão informada
- Promoção da mobilidade sustentável
- Balanço entre eficiência e ambiente

O projeto demonstra que é possível conciliar rapidez e sustentabilidade na mobilidade urbana

Questões?

Obrigado pela vossa atenção!

Diogo José Borges Dias
Diogo Lopes Azevedo

 github.com/diogoazevedo04/cin