

Otimização Multiobjetivo de Percursos Multimodais no Porto

Projeto de Computação Inspirada na Natureza

Diogo Dias PG60245, Diogo Azevedo PG61217

Mestrado em Inteligência Artificial
Universidade do Minho



Índice

Resumo	2
Introdução	4
Explicação	7
Metodologia Experimental	24
Conclusão	35

Resumo

A mobilidade urbana sustentável constitui um desafio central nas áreas metropolitanas modernas, exigindo soluções que equilibrem **eficiência temporal** e **impacto ambiental**.

Problema: Planeamento de rotas no Grande Porto combinando Metro, Autocarro (STCP) e Caminhada.

Objetivos Conflituosos:

1. Minimizar o **Tempo Total** (Rapidez).
2. Minimizar as **Emissões de CO_2** (Sustentabilidade).

Solução: Desenvolvimento de um sistema baseado no algoritmo **MOEA/D** com inicialização heurística e dados reais (GTFS).

Introdução

A abordagem experimental seguiu três fases:

1. **Modelação:** Construção de um **Grafo** com dados reais (GTFS) da STCP e Metro.
2. **Implementação:** Algoritmo MOEA/D em Python com operadores adaptados a grafos.
3. **Validação:** Criação de cenários de teste (Fácil, Médio, Difícil) e análise de métricas (Hipervolume etc).

Optámos pelo MOEA/D em detrimento de abordagens clássicas (Soma Ponderada) ou puramente baseadas em dominância (NSGA-II) porque:

- **Decomposição:** Transforma o problema complexo em subproblemas escalares, mantendo melhor a diversidade em frentes de Pareto não-convexas.
- **Eficiência:** O uso de vizinhanças ($T = 20$) reduz o custo computacional comparado com a classificação global de dominância.

Explicação

Estrutura do Grafo Multimodal

O problema é formulado como a procura do caminho mais curto bi-objetivo num grafo orientado $G = (V, E)$.

Camadas do Grafo:

1. **Metro:** +20 estações (Dados GTFS reais).
2. **STCP (Bus):** +2500 paragens.
3. **Pedonal:** Ligações até 450m ($1.2 \times$ Haversine).

Atributos das Arestas (e):

- t_e : Tempo (min).
- d_e : Distância (km).
- c_e : Emissões CO_2 ($d_e \times \text{fator}_{\text{modo}}$).

- m_e : modo de transporte $\in \{\text{metro, autocarro, pedonal}\}$.




Figura 1: Visualização da Rede Multimodal no Porto

Funções objetivo:

$$\min T(x) = \sum_{e \in E} t_e \cdot x_e$$

(Tempo Total)

$$\min C(x) = \sum_{e \in E} c_e \cdot x_e$$

(Emissões Totais)

Restrições de Viabilidade:

- **Caminhada:** Tempo total a pé ≤ 90 minutos.

$$\sum_{e \in E_{\text{ped}}} t_e \cdot x_e \leq 90 \text{ min}$$

- **Transbordos:** Máximo de 4 trocas de veículo.

$$\sum_{e \in E_{\text{transf}}} x_e \leq 4$$

O problema apresenta um espaço de procura vasto e discreto (+2500 paragens), desafiante para métodos clássicos.

Os Desafios:

- **Natureza Discreta:** Presença/Ausência de arestas (não há gradiente).
- **Ótimos Locais:** Existência de múltiplas soluções “boas” mas não ideais.
- **Trade-off Não-Linear:** A relação entre Tempo e CO₂ é complexa.

A Vantagem Evolutiva:

- **População:** Exploração simultânea de várias regiões do espaço de procura.
- **Equilíbrio:** Balanceamento entre diversidade (Exploração Global) e vizinhança (Exploração Local).
- **Flexibilidade:** Permite incorporar conhecimento do domínio (Inicialização Heurística).

Implementação: Inicialização Heurística

Ao contrário da inicialização aleatória comum, incorporamos **conhecimento do domínio** desde o início.

1. Geramos 100 vetores de peso λ uniformes.
2. Para cada vetor, executamos o algoritmo de **Dijkstra** com custos ponderados:

$$\text{cost}_{u,v} = \lambda_1 \cdot \frac{t_e}{t_{\max}} + \lambda_2 \cdot \frac{c_e}{c_{\max}}$$

3. Inclusão forçada de uma solução **100% Pedonal** (se existir), para garantir o extremo de 0 emissões.

Impacto: *População inicial diversa, válida e bem distribuída no espaço de objetivos, acelerando a convergência para a Frente de Pareto verdadeira.*

Função de Fitness

A aptidão de cada indivíduo combina a agregação de Tchebycheff com penalizações por violação de restrições.

1. Função Escalar (Tchebycheff):

Para um subproblema com vetor de pesos λ e ponto de referência ideal z^* :

$$g(x \mid \lambda) = \max_j \{ \lambda_j c \cdot | f_{j(x)} - z_j^* | \} + \text{Penalização}(x)$$

- **Objetivo:** Minimizar a distância ponderada ao ponto ideal (atualizado a cada geração).

2. Penalizações ($P(x)$): Restrições operacionais são convertidas em custos elevados para guiar a evolução:

- **Transbordos (> 4):** $+500 \times n^{\circ}$ transbordos extra
- **Tempo a Pé (> 90 min):** $+100 \times$ minutos extra

***Porquê?** Permite que rotas ligeiramente inválidas sirvam de “ponte” genética sem dominar a população final.*

Representação das Soluções

Ao contrário de vetores binários, utilizamos uma representação baseada em **caminhos sequenciais** (x) para garantir validade topológica.

Definição Formal: Seja $x = (v_1, v_2, \dots, v_k)$, onde:

- $v_i \in V$: Representa um nó (paragem de metro, autocarro ou ponto pedonal).
- $v_1 = s$ (Origem virtual) e $v_k = t$ (Destino virtual).
- $(v_i, v_{i+1}) \in E$: Cada par consecutivo é uma aresta existente no grafo.
- **Flexibilidade:** Permite caminhos de tamanho variável.

Representação: Exemplo de um Cromossoma

Explicação

Cada indivíduo é uma sequência ordenada de nós que representa uma viagem completa e válida.

[S, metro_12, metro_34, stcp_21, stcp_22, T]

Interpretação das Arestas:

- 1. Walk:** $S \rightarrow \text{metro}_{12}$
- 2. Metro:** $\text{metro}_{12} \rightarrow \text{metro}_{34}$
- 3. Transfer:** $\text{metro}_{34} \rightarrow \text{stcp}_{21}$
(Walk)
- 4. Bus:** $\text{stcp}_{21} \rightarrow \text{stcp}_{22}$
- 5. Walk:** $\text{stcp}_{22} \rightarrow T$

Avaliação deste Caminho:

Tempo Total (T):	32 min
Emissões (CO_2):	980 g
Transbordos:	4
Violações:	0 (Válido)

Devido à natureza sequencial das soluções (**caminhos em grafos**), foi necessário definir operadores genéticos adaptados a sequências de nós, em vez de operadores clássicos aplicáveis a vetores binários ou reais.

Operador de Mutação

A mutação atua como um operador de **refinamento inteligente** para introduzir diversidade e refinar a rota.

Lógica ($P_m = 0.8$):

1. Seleccionam-se dois índices aleatórios $i < j$.
2. O segmento intermédio $p[i : j]$ é **removido**.
3. A ligação entre $p[i]$ e $p[j]$ é **reconstruída** via Dijkstra.

Exemplo Prático:

Rota Original:

$$A \rightarrow B \rightarrow C \rightarrow D \rightarrow E$$

1. Corte (Remove B..D):

$$A \rightarrow \dots \rightarrow E$$

2. Reconstrução (Dijkstra): Acha novo caminho entre A e E. Ex:

$$A \rightarrow X \rightarrow Y \rightarrow E$$

Modos de Reconstrução:

- **Exploratório (Evolução):** Minimiza aleatoriamente Tempo t_e ou CO₂.
- **Orientado (Inicialização):** Minimiza custo ponderado com **perturbação aleatória** ($\delta \in [-5\%, +5\%]$) para escapar de mínimos locais.

Operador de Crossover (Nó Comum)

Explicação

Combina estratégias de dois pais mantendo a validade topológica através de pontos de interseção.

Lógica ($P_c = 0.8$):

1. Identifica nós comuns $C = p_1 \cap p_2$.
2. Se $|C| \geq 3$, escolhe um nó de corte aleatório n^* .
3. **Filho:** Cabeça do Pai 1 + Cauda do Pai 2 (unidos em n^*).

$$\text{offspring} = p_1[1 : n^*] + p_2[n^* : \text{fim}]$$

Vantagens:

- Garante sempre um caminho contínuo (sem “teletransporte”).
- Preserva subestruturas eficientes dos pais.

Exemplo Prático:

Pai 1 (Foco Metro):

$$A \rightarrow B \rightarrow \text{Trindade} \rightarrow D \rightarrow E$$

Pai 2 (Foco Bus):

$$X \rightarrow Y \rightarrow \text{Trindade} \rightarrow Z \rightarrow W$$

Filho Gerado:

$$A \rightarrow B \rightarrow \text{Trindade} \rightarrow Z \rightarrow W$$

O MOEA/D não usa seleção global. Usa **cooperação local** entre subproblemas vizinhos.

1. Conceito de Vizinhança:

- Cada subproblema i tem $T = 20$ vizinhos ($N(i)$) com vetores de peso λ matematicamente mais próximos.
- **Lógica:** Problemas com objetivos parecidos (ex: priorizar 90% Tempo) ajudam-se mutuamente.

2. Ciclo de Atualização:

A. Seleção: Pais vêm da vizinhança: $P_1 = i, P_2 \in N(i)$.

B. Reprodução: Gera-se um filho (Crossover + Mutação).

C. Substituição: O filho tenta substituir **todos** os vizinhos $j \in N(i)$.

Se $g(\text{filho} \mid \lambda_j) < g(\text{vizinho}_j \mid \lambda_j)$, **o filho substitui o vizinho.**

Vantagem: Reduz a pressão seletiva global, permitindo que soluções especializadas (boas num trade-off específico) sobrevivam e evoluam, garantindo uma **Frente de Pareto bem distribuída.**

Para garantir resultados úteis, aplicamos filtros rigorosos para remover soluções redundantes ou inválidas.

1. Dominância Penalizada: Ao atualizar a frente, consideramos as penalizações diretamente nos objetivos.

$$f'(x) = (T(x) + \text{viol}, C(x) + \text{viol})$$

Se uma solução viola restrições, os seus valores de Tempo e CO₂ “pioram”, sendo facilmente dominada e descartada por soluções válidas.

2. Poda por Epsilon-Dominance: Evita o crescimento infinito do arquivo externo removendo soluções “gémeas”.

Critério de Exclusão: Uma solução x é descartada se já existir y tal que:

$$|T(x) - T(y)| \leq \varepsilon_t \quad \text{E} \quad |C(x) - C(y)| \leq \varepsilon_c$$

Tolerâncias:

- $\varepsilon_t = 0.3$ min (Tempo)
- $\varepsilon_c = 1.0$ g (CO₂)

Metodologia Experimental

Para validar a solução, criámos cenários com graus de dificuldade crescentes.

Nível	Distância Aérea	Desafio
Fácil	0.5 - 4.0 km	Domínio pedonal
Médio	5.0 - 9.0 km	Necessidade de transporte público
Difícil	10.0 - 17.0 km	Múltiplos transbordos necessários

Para garantir a comparabilidade dos resultados, todos os testes utilizaram a seguinte configuração rigorosa.

1. Hiperparâmetros (MOEA/D)

Parâmetro	Valor
População (N)	100
Gerações	50
Vizinhos (T)	20
Prob. Crossover	0.8
Prob. Mutação	0.8

Penalizações (Restrições):

- Transbordos (> 4): $500 \times$ excesso
- Tempo a Pé (> 90 min): $100 \times$ excesso

2. Parâmetros do Grafo e Ambiente

Parâmetro	Valor
Raio Conexão Pedonal	0.45 km
Velocidade a Pé	5.0 km/h
Tempo Transbordo	2.0 min
Fator CO_2 (Metro)	40.0 g/km
Fator CO_2 (Bus)	109.9 g/km
Fator CO_2 (Pé)	0 g/km

A qualidade da solução é avaliada segundo dois eixos principais: a aproximação à frente ótima e a distribuição das soluções.

1. Convergência (Qualidade) Monitorizamos a evolução ao longo das gerações:

- **Hipervolume (HV)**
- **Extremos:** Evolução dos mínimos de Tempo e CO₂.
- **Tamanho da Frente:** Contagem de soluções não-dominadas.
- **Dispersão Visual:** Análise gráfica da cobertura entre os extremos “Rápido” e “Ecológico”.
- **Estatísticas:** Média, Mínimo e Máximo para Tempo e CO₂.




Figura 2: Cenário Fácil




Figura 3: Cenário Médio




Figura 4: Cenário Difícil




Figura 5: Cenário Fácil




Figura 6: Cenário Médio




Figura 7: Cenário Difícil




Figura 8: Cenário Fácil




Figura 9: Cenário Médio




Figura 10: Cenário Difícil

1. Complexidade vs. Quantidade
2. Controlo de Crescimento
3. O Efeito “Escada”




Figura 11: Cenário Fácil




Figura 12: Cenário Médio




Figura 13: Cenário Difícil

- Crescimento acentuado nas primeiras gerações (efeito da Inicialização Heurística).
- Estabilização por volta da geração 30.
- Confirma a robustez do algoritmo na aproximação da frente ótima.

Para concretizar os resultados, analisamos três perfis de viagem extraídos da Frente de Pareto do Cenário Médio.

Perfil	Tempo (min)	CO ₂ (g)	Modo Dominante
Rápido	33.9	622	Bus > Metro > Walk
Equilibrado	60.1	193	Walk > Metro > Bus
Ecológico	86.8	62	Walk > Metro

```
===== SOLUÇÃO #20 =====
Tempo total: 33.9 min
CO2 total: 622 g
Paragens: 20
Transbordos: 4
Distância a pé: 0.54 km

Resumo por modo:
WALK: 10.5 min | 0.54 km | 3 arestas
METRO: 5.0 min | 2.43 km | 3 arestas
BUS: 18.3 min | 4.78 km | 13 arestas

Caminho:
WALK: origin → metro_5729
5.6 min | 0.39 km
METRO: metro_5729 → metro_5706
5.0 min | 2.43 km
WALK: metro_5706 → bus_CMS4
3.9 min | 0.16 km
BUS: bus_CMS4 → bus_1MST1
18.3 min | 4.78 km
WALK: bus_1MST1 → destination
1.0 min | 0.00 km
```

Figura 14: Perfil Rápido

```
===== SOLUÇÃO #0 =====
Tempo total: 60.1 min
CO2 total: 193 g
Paragens: 17
Transbordos: 4
Distância a pé: 4.07 km

Resumo por modo:
WALK: 52.8 min | 4.07 km | 11 arestas
METRO: 5.0 min | 2.43 km | 3 arestas
BUS: 2.3 min | 0.87 km | 2 arestas

Caminho:
WALK: origin → metro_5729
5.6 min | 0.39 km
METRO: metro_5729 → metro_5706
5.0 min | 2.43 km
WALK: metro_5706 → bus_NOC
32.4 min | 2.53 km
BUS: bus_NOC → bus_CCB1
2.3 min | 0.87 km
WALK: bus_CCB1 → destination
14.8 min | 1.15 km
```

Figura 15: Perfil Equilibrado

```
===== SOLUÇÃO #23 =====
Tempo total: 86.8 min
CO2 total: 62 g
Paragens: 21
Transbordos: 2
Distância a pé: 6.65 km

Resumo por modo:
WALK: 83.8 min | 6.65 km | 18 arestas
METRO: 3.0 min | 1.56 km | 2 arestas

Caminho:
WALK: origin → metro_5729
5.6 min | 0.39 km
METRO: metro_5729 → metro_5711
3.0 min | 1.56 km
WALK: metro_5711 → destination
78.1 min | 6.26 km
```

Figura 16: Perfil Ecológico

Embora o foco tenha sido a implementação do MOEA/D, a análise comparativa teórica e procedimental revela:

1. **Multimodalidade Eficaz**
2. **Com vs Sem Inicialização Heurística**
3. **Operadores com conhecimento do domínio**
4. **Taxa de mutação**
5. **Cobertura da Frente**

Conclusão

1. **Eficácia do MOEA/D:** A decomposição provou ser eficaz em problemas de rotas multimodais.
2. **Hibridização:** A incorporação de **Dijkstra** na inicialização e mutação foi crítica para evitar caminhos inválidos.
3. **Aplicabilidade:** O sistema gera opções úteis para diferentes perfis de utilizador.
4. **Distribuição:** alcançamos uma boa cobertura da Frente de Pareto;

Trabalho Futuro:

- Comparação experimental direta com NSGA-II.
- Novos critérios (ex: custo monetário etc)

[1] Câmara Municipal do Porto. **Infraestruturas e Mobilidade — Dados GTFS**. 2024.

[2] C. A. Coello Coello. «Evolutionary Multi-Objective Optimization: A Historical View». **IEEE Comp. Int. Mag.**, 2006.

[3] K. Deb. **Multi-Objective Optimization Using Evolutionary Algorithms**. John Wiley & Sons, 2001.

[4] K. Deb et al. «A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II». **IEEE Trans. Evol. Comp.**, 2002.

[5] A. E. Eiben e J. E. Smith. **Introduction to Evolutionary Computing**. Springer, 2003.

[6] D. E. Goldberg. **Genetic Algorithms in Search, Optimization and Machine Learning**. Addison-Wesley, 1989.

[7] J. Knowles e D. Corne. «Approaches to Multiobjective Optimization». **Evolutionary Computation**, 2006.

[8] Metro do Porto. **Política de Sustentabilidade e Ambiente**. Relatório Institucional, 2024.

[9] STCP. **Política Energética e Sustentabilidade**. Relatório Institucional, 2024.

[10] Q. Zhang e H. Li. «MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition». **IEEE Trans. Evol. Comp.**, 2007.